

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

ZAVRŠNI RAD br. 880

**PRIMJENA METODA STATISTIKE I STROJNOG UČENJA ZA
ANALIZU VODNIH VALOVA**

Ana Francesca Stama

Zagreb, lipanj 2023.

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

ZAVRŠNI RAD br. 880

**PRIMJENA METODA STATISTIKE I STROJNOG UČENJA ZA
ANALIZU VODNIH VALOVA**

Ana Francesca Stama

Zagreb, lipanj 2023.

Zagreb, 10. ožujka 2023.

ZAVRŠNI ZADATAK br. 880

Pristupnica: **Ana Francesca Stama (0036531912)**
Studij: Elektrotehnika i informacijska tehnologija i Računarstvo
Modul: Računarstvo
Mentor: prof. dr. sc. Damir Pintar

Zadatak: **Primjena metoda statistike i strojnog učenja za analizu vodnih valova**

Opis zadatka:

Poplave mogu uzrokovati značajne gospodarske štete i ugroziti ljudske živote. Upravljanje rizicima od poplava stoga predstavlja važan aspekt gospodarenja vodama. Povijesni podatci o protocima i vodostajima na vodomjernim postajama na vodotocima uobičajeno se koriste kao temelji za opis i predviđanje budućih poplavnih događaja. Kroz primjenu metoda statistike i strojnog učenja moguće je stvoriti deskriptivne i prediktivne modele koji će domenskim stručnjacima pružiti važne informacije za ostvarivanje boljih rješenja u upravljanju rizicima od poplava. Vaš zadatak je na osnovu dobivenih hidroloških podataka provesti eksploratornu i dubinsku analizu, uz naglasak na povezanost oblika vodnog vala sa dodatnim parametrima koji opisuju njegove karakteristike. Konačno rješenje potrebno je realizirati u obliku programske skripte koje će implementirati razvijene modele i evaluirati njihovu učinkovitost uz komparativnu analizu korištenih metoda.

Rok za predaju rada: 9. lipnja 2023.

SADRŽAJ

1. Uvod	1
2. Područje istraživanja	2
3. Podaci	4
4. Metode	7
4.1. Izdvajanje vodnih valova	7
4.2. Grupiranje vodnih valova	8
4.2.1. Grupiranje prema obliku	9
4.2.2. Grupiranje prema dodatnim indikatorima	12
4.3. Vrednovanje klastera	13
5. Rezultati	17
5.1. Izdvojeni vodni valovi	17
5.2. Pregled dobivenih klastera	19
5.2.1. Grupiranje prema obliku, <i>B-spline</i> interpolacija	20
5.2.2. Grupiranje prema obliku, Fourier	20
5.2.3. Grupiranje prema indikatorima I1-I7	21
5.2.4. Grupiranje prema indikatorima I1, I2, I3	22
5.2.5. Grupiranje prema indikatorima I1, I2	23
5.2.6. Grupiranje prema indikatorima I1, I3	24
5.2.7. Grupiranje prema indikatorima I1, I4	25
5.2.8. Grupiranje prema indikatorima I2, I4	25
5.2.9. Grupiranje prema indikatorima I1, I2, I3, I4	25
5.2.10. Grupiranje prema indikatorima I5, I6, I7	26
5.2.11. Grupiranje prema indikatorima I5, I7	26
5.3. Usporedba rezultata	27

6. Zaključak	35
Literatura	36

1. Uvod

Poplave mogu biti razorna prirodna pojava i uzrokovati značajne gospodarske i financijske štete, ali i ozbiljno ugroziti ljudske živote. Zbog toga upravljanje rizicima od poplava i njihovo predviđanje predstavljaju važan aspekt gospodarenja vodama.

Povijesni podaci o protocima i vodostajima na vodomjernim postajama na vodotocima uobičajeno se koriste kao temelj za opis i predviđanje budućih poplavnih događaja. Kroz primjenu metoda statistike i strojnog učenja moguće je stvoriti deskriptivne i prediktivne modele koji će domenskim stručnjacima pružiti važne informacije za ostvarivanje boljih rješenja u upravljanju rizicima od poplava. U ovom radu naglasak je na statističkoj analizi i grupiranju vodnih valova u klastere primjenom nenadziranog strojnog učenja kako bi domenski stručnjaci kasnije imali osnovu za identifikaciju i klasifikaciju poplavnih događaja. Analiza je provedena u programskom jeziku R.

Rad je strukturiran kako slijedi: Nakon uvodnog dijela u prvom poglavlju, u drugom je poglavlju objašnjena domena istraživanja i predstavljena najbitnija terminologija, dok su u trećem poglavlju opisani podaci nad kojima je provedena analiza. Zatim su u četvrtom poglavlju navedene i objašnjene metode korištene u analizi hidroloških podataka (izdvajanje vršnih protoka i grupiranje). U petom su poglavlju predstavljeni rezultati i usporedbe dobivenih klastera. Za kraj, zaključak i prijedlog budućeg nastavka rada dani su u šestom poglavlju.


2. Područje istraživanja

U ovom je poglavlju prikazan kratki pregled područja istraživanja te je navedena najbitnija terminologija potrebna za razumijevanje nastavka rada i same analize. Također je predstavljena motivacija iza koncepta grupiranja vodnih valova.


Velika voda podrazumijeva pojavu naglog povećanja vodostaja (razina vode nekog vodnog tijela), odnosno protoka (volumen vode koji protječe poprečnim presjekom u jedinici vremena [1]) u nekom vodotoku, a kada se dosegnu maksimalne vrijednosti tih veličina, dolazi do njihovog postupnog opadanja [2]. Neki od uzroka velikih voda na rijekama su jake kiše, topljenje nagomilanog snijega i leda, formiranje ledenih barijera, rušenje brana ili nasipa itd. Protok u jedinici vremena može se grafički prikazati u obliku hidrograma. Na slici 2.1 (a) prikazan je hidrogram prosječnih dnevnih protoka na VS Zagreb na temelju hidroloških podataka koji su opisani u nastavku ovog rada, a nad kojima je provedena analiza. Odgovarajući hidrogram može se nazvati poplavnim valom, s obzirom na to da prilikom pojave maksimalnog protoka često dolazi do izlivanja vode iz korita vodotoka i preplavlivanja okolne površine [3]. Na slici 2.1 (b) prikazan je uvećan poplavni val za razdoblje od 17. do 30. listopada 1961. godine.

Poplave predstavljaju veliku opasnost za ljudsku zajednicu i mogu imati razoran učinak na financijski, društveni i ekološki aspekt zahvaćene regije. Najveća dosadašnja poplava na području Republike Hrvatske dogodila se u noći s 25. na 26. listopada 1964. godine. Zbog dugotrajne kiše u gornjem toku rijeke Save došlo je do porasta vodostaja rijeke i ona se izlila iz korita te probila nasipe i poplavila trećinu grada. Sava je prekrila više od 6 tisuća hektara gradskog područja na kojem je živjelo oko 180 tisuća ljudi, a 17 je osoba smrtno nastradalo [4]. U novijoj povijesti zapamćene su velike poplave uzrokovane probijanjem savskih nasipa na mjestima kod Rajevog Sela i Račinovaca, do kojih je došlo uslijed ekstremnih količina oborina i višednevne ciklone stacionirane nad jugoistočnom Europom, koje su 2014. godine pogodile istočnu Hrvatsku [5].

Klasifikacija poplavnih vodnih valova važan je dio upravljanja rizikom od poplava jer predstavlja osnovu za izradu raznih projektnih rješenja unutar sustava za pasivnu (izgradnja nasipa) i aktivnu (uređenje sliva, uređenje korita vodotoka te izgradnja aku-



(a) Hidrogram VS Zagreb za period 1960-2019.



(b) Poplavni val 1961. iz godine


Slika 2.1: Grafički prikaz hidroloških podataka.

mulacija retencija i oteretnih kanala) zaštitu područja od poplava [2]. Klasifikacijom vodnih valova omogućeno je pojednostavljenje kompleksnosti i varijabilnosti poplava. U području hidrologije koristi se za razumijevanje varijabilnosti riječnog toka, istraživanje utjecaja protoka na biološke zajednice i ekološke procese, pomoć pri hidrološkom modeliranju itd. [6]. Metode grupiranja obično uključuju neki oblik nenadziranog strojnog učenja ili analize klastera, što rezultira objektivnijim i reproducibilnim definicijama klasa u odnosu na grupiranje u predefinirane klase [7].

3. Podaci

U ovom su poglavlju ukratko opisani podaci nad kojima je provedena analiza i njihovi atributi, vodomjerna stanica s koje su navedeni podaci prikupljeni te nekoliko manjih modifikacija koje su učinjene radi lakše analize podataka.

Za potrebe analize korišteni su prikupljeni podaci dnevnog protoka rijeke Save u razdoblju od 1. siječnja 1960. godine do 31. prosinca 2019. godine, dobiveni od strane Državnog hidrometeorološkog zavoda na vodomjernoj stanici (VS) Zagreb. VS Zagreb s radom je započela 1. siječnja 1849. godine. Nalazi se u južnom dijelu Zagreba i pripada Crnomorskom slivu. Njena topografska površina iznosi 12 450.000 km², dok udaljenost od ušća iznosi 664.20 km. Najmanji vodostaj i protok izmjereni su 23. kolovoza 1993. godine i iznose 338 cm, odnosno 46.50 m³/s, a najveći vodostaj i protok izmjereni su za vrijeme poplave u Zagrebu 26. listopada 1964. godine te iznose 514 cm, odnosno 3126 m³/s. [8] Na slici 3.1 prikazan je poprečni presjek korita rijeke Save na vodomjernoj stanici.



Slika 3.1: Poprečni presjek rijeke Save na VS Zagreb (izvor: DHMZ[8])

Analiza je provedena na dva skupa podataka u csv formatu. Prvi skup podataka sastoji se od 21915 opservacija te sadrži dva atributa: *date*, datum u standardnom formatu, i *flow* koji predstavlja prosječan dnevni protok u m³/s. Drugi se skup podataka

također sastoji od 21915 opservacija te sadrži sedam atributa: *day*, *month*, *year*, *flow*, *hyear*, *baseflow* i *date*. Prva tri atributa sadržana su u zadnjem, a atributi *year* i *hyear* su jednaki tako da je iz ovog skupa podataka iskorišten samo atribut *baseflow* koji predstavlja bazni dotok, tj. dio ukupnoga otjecanja koji u vodotok stiže uglavnom iz podzemnih voda, ali i iz jezera i ledenjaka tijekom dugih razdoblja kada nema oborina ili otapanja snijega [1]. Bazni se protok koristi za određivanje kraja i početka pojedinih vodnih valova. U tablicama 3.1 i 3.2 je kao primjer prikazan odabrani podskup opservacija iz prvog, odnosno drugog skupa podataka (pritom je atribut *baseflow* radi preglednosti zaokružen na cjelobrojnu vrijednost).

Tablica 3.1: Prvi skup podataka prije obrade.

date	flow
09/04/1960	297
01/01/1961	425
26/09/1962	179
13/11/1963	534

Tablica 3.2: Drugi skup podataka prije obrade.

day	month	year	flow	hyear	baseflow	date
9	4	1960	297	1960	277	1960-04-09
1	1	1961	425	1961	397	1961-01-01
26	9	1962	179	1962	130	1962-09-26
13	11	1963	534	1963	232	1961-11-13

Nakon što je prvi skup podataka učitán u podatkovni okvir, pridružen mu je parametar *baseflow* na temelju zajedničkog atributa *date* iz drugog skupa podataka. Novi podatkovni okvir sadrži 37 opservacija s nedefiniranom vrijednosti atributa *baseflow*. S obzirom na to da takve opservacije sačinjavaju tek 0.17 % cjelokupnog skupa podataka, uklanjaju se iz podatkovnog okvira i ne uzimaju u obzir prilikom daljnje analize.

Također su izračunata i dodana dva nova parametra u podatkovni okvir: *year* koji predstavlja godinu dotične opservacije, te *flowdiff* kao razlika između protoka i baznog protoka. U tablici 3.3 prikazan je odabrani podskup opservacija iz skupa podataka nakon opisane obrade (atribut *baseflow* je zaokružen kao što je ranije spomenuto). Novi se podatkovni okvir sastoji od 21878 opservacija i pet atributa/stupaca. Grafički prikaz prosječnih dnevnih protoka u jedinici vremena (hidrogram), u razdoblju od 1960. do

2019. godine prikazan je u prethodnom poglavlju (Slika 2.1).

Tablica 3.3: Skup podataka nakon obrade.

date	flow	year	baseflow	flowdiff
1960-04-09	297	1960	277	19.6
1961-01-01	425	1961	397	28.4
1962-09-26	179	1962	130	49.0
1963-11-13	534	1963	382	153.2

4. Metode


U ovom su poglavlju navedene i opisane korištene metode za izdvajanje vodnih valova i njihovo grupiranje. Pritom su je pojašnjen pojam interpolacije, navedena dva načina na koja su podaci interpolirani i odvojeni postupci grupiranja prema obliku i prema dodatnim indikatorima. Zatim su prikazani izračunati indikatori i navedene kombinacije indikatora prema kojima su podaci grupirani. Također je objašnjeno zašto je bitno vrednovati klastere i na koji je način to učinjeno u ovom radu.

4.1. Izdvajanje vodnih valova

Izdvajanje nezavisnih vodnih valova obično se provodi na jedan od dva načina: metodom prekoračenja praga (engl. *peak over threshold*) i metodom godišnjih maksimuma (engl. *annual maxima*). Metoda prekoračenja praga podrazumijeva definiranje određenog praga dnevnog protoka stručnom analizom tako da se svaka vrijednost dnevnog protoka iznad tog praga smatra dijelom vala. Početak i kraj vala lako se određuje kao prva, odnosno zadnja točka u kojoj protok prelazi definirani prag. Sam prag određuju domenski stručnjaci nizom računa, stoga se u ovom radu neće ulaziti u postupak. Metoda godišnjih maksimuma temelji se na pronalaženju niza godišnjih ekstrema (najveća vrijednost protoka u određenom profilu rijeke, registriranu tijekom godine [2]) odabirom maksimalnog dnevnog protoka (Q_{max}) za svaku godinu iz danog skupa podataka. Pritom se podrazumijeva da su maksimalni godišnji protoci slučajne veličine i međusobno nezavisni [1].

U ovom radu korištena je metoda godišnjih maksimuma, pri čemu su početak i kraj vala definirani kao točke u kojima se prosječan dnevni protok i bazni protok izjednačuju. Na slici 4.1 je kao primjer prikazan hidrogram za razdoblje 1960-1970. na kojem su crvenim linijama označeni datumi na koje je te godine dnevni protok dosegao svoj godišnji maksimum.

Način na koji je to izvedeno jest dodavanjem atributa *flowDesc* koji je mogao primiti jednu od dvije vrijednosti: "peak" u slučaju da se na odabrani datum dogodio




Slika 4.1: Označeni vršni protoci (Q_{max}) za period 1960-1970.

godišnji maksimum, ili *NA* (nedefinirana vrijednost) u suprotnom. Zatim je iteracijom po datumima vršnog protoka pronađen početak i kraj vodnog vala na sljedeći način: Pronađen je najbliži datum datumu vršnog toka na koji je atribut *flowdiff* bio približno jednak 0. Pritom je najbliži takav datum koji je manji od datuma vršnog toka nazvan početkom vodnog vala te je opservaciji s odgovarajućim datumom kao vrijednost atributa *flowDesc* postavljeno "waveStart". Svim opservacijama između početka vodnog vala i njegova vršnog protoka kao vrijednost atributa *flowDesc* postavljeno je "leftSegment". Sukladno tome, najbliži takav datum koji je veći od datuma vršnog protoka nazvan je krajem vodnog vala te je opservaciji s odgovarajućim datumom kao vrijednost atributa *flowDesc* postavljeno "waveEnd". Opservacijama između vršnog protoka vodnog vala i njegova kraja kao vrijednost atributa *flowDesc* postavljeno je "rightSegment". Također je pridružen atribut *flowDay* koji predstavlja redni dan trajanja vodnog vala, skaliran tako da je redni dan datuma vršnog toka 0, dok lijevi i desni rep vala poprimaju negativne, odnosno pozitivne vrijednosti. Ovaj je postupak ilustriran hodo-gramom na slici 4.2.

4.2. Grupiranje vodnih valova

Grupiranje (engl. *clustering*) je često korištena metoda nenadziranog strojnog učenja za statističku analizu podataka. To je proces podjele skupa podataka u podskupove (klase, klastere, engl. *clusters*) koji dijele određene karakteristike tako da su opser-



Slika 4.2: Hodogram dodavanja segmenata.


vacije u pojedinoj grupi međusobno što sličnije, a opservacije između grupa što različite. Najčešće korištene vrste grupiranja podataka su hijerarhijsko grupiranje (engl. *hierarchical clustering*) i particijsko grupiranje (engl. *k-means clustering*). Hijerarhijski algoritmi pronalaze uzastopne klastere pomoću prethodno uspostavljenih klastera i pokušavaju uspostaviti hijerarhiju između pojedinih klastera te se koriste kad je broj klasa nepoznat, dok particijski algoritmi određuju sve klastere u danom trenutku te broj klasa mora biti fiksiran i unaprijed poznat [9].

Za potrebe ovog rada korišteno je particijsko grupiranje s fiksno određenim brojem od tri klase. Vodni valovi grupirani su na dva načina: grupiranje prema obliku i grupiranje prema dodatnim indikatorima. Za samo grupiranje korištena je funkcija *kmeans* iz paketa *stats*.

4.2.1. Grupiranje prema obliku

Oblik vodnog vala bitan je parametar koji domenskim stručnjacima omogućuje predviđanje budućih projektnih događaja. Cilj ovakvog grupiranja jest kasnije iskoristiti dobivene klastere kako bi se definirao oblik sintetičkog/projektnog hidrograma (engl. *design hydrograph*). Grupiranje vodnih valova prema obliku podrazumijeva da su oblici reprezentirani u obliku funkcijskih podataka definiranih kao kontinuirani podaci koji ne ovise o odabiru specifičnih hidroloških karakteristika poput vršnog protoka, volumena, trajanja i ostalih parametara koji opisuju oblik vala, već koriste sve informacije sadržane u samom hidrogramu [10]. Ovi se podaci obrađuju funkcijskom analizom koja obuhvaća beskonačnodimenzijske vektorske prostore, uz dodatne strukture na njima poput topologije.

Prvi korak funkcijske analize je interpolacija, tj. konstrukcija funkcijskog oblika podataka (funkcije) iz danih diskretnih točaka. Ideja interpolacije je naći funkciju koja prolazi kroz dani skup diskretnih točaka nadajući se pritom da će funkcija u točkama koje nemamo u danom skupu poprimiti vrijednosti koje su što bliže stvarnima. Na slici 4.3 ilustriran je postupak interpolacije točaka.




Slika 4.3: Postupak interpolacije (izvor: Brunner, 2018 [10]).

Postoji mnogo vrsta interpolacije, a neke od najčešće korištenih uključuju polinomialnu interpolaciju, trigonometrijsku interpolaciju, interpolaciju splajnovima i dr. Za potrebe analize korištena je engl. *B-spline* interpolacija (numerička funkcija sastavljena od po dijelovima polinomnih funkcija) i Fourierova interpolacija (primjena Fourierovih transformacija). Splajnovi se uobičajeno koriste za interpolaciju neperiodičkih točaka, dok se Fourierove transformacije češće koriste za interpolaciju periodičkih točaka.

Kako bi se podaci mogli interpolirati i kasnije grupirati, svi izdvojeni vodni valovi moraju imati jednak interval nad kojim će se funkcijski podaci evaluirati. To u slučaju danih hidroloških podataka znači da bi svi vodni valovi trebali biti definirani nad jednakim brojem točaka, tj. datuma. S obzirom na to da u pravilu nije slučaj da svi valovi jednako dugo traju, po potrebi su produljeni repovi vodnih valova tako što su pridijeljene ekstenzije vodnim valovima koji su "prekratki", odnosno nemaju dovoljno točaka za interpolaciju i grupiranje. To je napravljeno tako da su pronađene najmanja i najveća vrijednost atributa *flowDay* i postavljene u varijable *leftmostDay*, odnosno *rightmostDay*. U slučaju da je razlika između datuma početka vala i datuma vršnog protoka manja od vrijednosti varijable *leftmostDay*, odgovarajućem je vodnom valu postavljena ekstenzija lijevog repa tako da su svakom datumu između početka vodnog vala i datuma koji je udaljen od datuma vršnog protoka za vrijednost varijable *leftmostDay* postavljene vrijednosti atributa *flowDesc*, *flowDay*, *flowdiff* redom na "leftExtension", skaliran redni broj dana trajanja vodnog vala, 0. Na isti je način po potrebi postavljena ekstenzija desnog repa vodnog vala u slučaju da je razlika između datuma kraja vala i datuma vršnog toka manja od vrijednosti varijable *rightmostDay*, uz jedinu razliku između vrijednosti atributa *flowDesc* koja je postavljena na "rightExtension".

Ovaj je postupak ilustriran na hodogramu prikazanom na slici 4.4.




Slika 4.4: Hodogram dodavanja ekstenzija.

Također, podaci su pretvoreni u bezdimenzionalne tako što je razlika prosječnog dnevnog protoka i baznog protoka podijeljena s volumenom, tj. površinom ispod krivulje, te je taj podatak spremljen u novi atribut *flowScaled*. Tako se vrijednost atributa *flowdiff*, odnosno y-vrijednost kod interpolacije, svodi na vrijednosti između 0 i 1. Na slici 4.5 prikazan je primjer vodnog vala iz 1961. godine u originalnom obliku (a) i nakon ekstenzije repova i skaliranja (b).


Prvi korak interpolacije podataka bio je generiranje baznih polinomijalnih funkcija za evaluaciju podataka. To je postignuto funkcijama *create.bspline.basis* i *create.fourier.basis* iz paketa *fda*. Pritom se funkcijama kao argumenti moraju predati broj točaka nad kojima se izvodi interpolacija te stupanj polinoma kojima ju želimo izvesti. Na slici 4.6 prikazane su bazne funkcije B-splajna reda 4 i reda 10 na intervalu $[0, 1]$, dok su na slici 4.7 prikazane Fourierove bazne funkcije također reda 4 i reda 10 na intervalu $[0, 1]$. Nakon vizualne procjene različitih stupnjeva polinoma odabrani su polinomi stupnja 10 jer bolje odgovaraju obliku izdvojenih vodnih valova. Na slici 4.8 su kao primjer prikazane točke koje pripadaju vodnom valu iz 1963. godine i njihova interpolacija. B-spline interpolacija prikazana je crvenom bojom, dok je interpolacija Fourierovim transformacijama prikazana plavom bojom. Za samu interpolaciju svih izdvojenih vodnih valova iskorištena je funkcija *smooth.basis* iz paketa *fda*.

Nakon interpolacije su izvučeni dobiveni koeficijenti za svaku od dvije interpolacije koji su zatim kao argument predani funkciji za partijsko grupiranje.

Nakon interpoliranja točaka formirana je jedna grupa klastera na temelju podataka interpoliranim engl. B-spline interpolacijom i druga grupa na temelju podataka inter-



(a) Prije transformacije




(b) Nakon transformacije

Slika 4.5: Vodni val iz 1961. godine prije i nakon transformacije.


poliranim Fourierovim transformacijama.

4.2.2. Grupiranje prema dodatnim indikatorima

Drugi način grupiranja vodnih valova koji je proveden u ovom radu jest grupiranje prema dodatnim indikatorima izvedenim iz osnovnog skupa podataka. U podatkovni okvir dodano je sedam novih parametara/indikatora te su vodni valovi grupirani na temelju njihovih kombinacija. Tablica 4.1 prikazuje izračunate indikatore i njihov opis. Od dostupnih podataka, parametri izravno hidrološke prirode kojima se poplavni valovi uobičajeno opisuju su vršni protok, volumen i trajanje vodnog vala [1], dok su ostali parametri odabrani zbog detaljnijeg opisa karakteristika vodnog vala, režima



Slika 4.6: Bazine funkcije B-splajna.



Slika 4.7: Bazine Fourierove funkcije.

protoka te ekoloških funkcija vodotoka. Analiza je provedena nad normaliziranim i standardiziranim indikatorima, no u nastavku rada bit će prikazana samo analiza nad standardiziranim indikatorima zbog bolje vizualizacije. Indikatori su standardizirani uz pomoć funkcije *scale* iz osnovnog paketa. Ova funkcija skalira podatke tako da prosječna vrijednost podataka jednaka 0 na temelju sljedeće formule:


$$x_{skalirano} = \frac{vrijednost - prosjek}{std}$$

gdje std predstavlja standardnu devijaciju.

Od izračunatih indikatora formirani su klasteri na temelju kombinacija indikatora prikazanih u tablici 4.2.

4.3. Vrednovanje klastera

Kod grupiranja podataka u klastere postavlja se pitanje jesu li ti klasteri valjani, odnosno reprezentiraju li dobro odgovarajući skup podataka ili su pak tvorevine algoritma grupiranja. Može se dogoditi da algoritam proizvede nekoliko valjanih klastera koji reprezentiraju stvarnu strukturu ili odnose između podataka, ali uz to proizvede



Slika 4.8: Interpolacija vodnog vala iz 1963. godine

i jedan do dva klastera u koje se svrstavaju podaci koji su na neki način "odbačeni". Podaci koji pripadaju tim klasterima nemaju zapravo nikakve međusobno slične karakteristike na temelju kojih su grupirani zajedno, već jednostavno ne pripadaju nikamo drugdje.

Jedan od načina na koji se određeni klaster može validirati jest provjerom hoće li odabrani klaster opstati nad vjerodostojnim varijacijama izvornog skupa podataka. U tu se svrhu koristi bootstrap, analitička tehnika ponovnog uzorkovanja koja podrazumijeva ponovljeno računanje odabrane statistike temeljeno na velikom broju slučajnih uzoraka odabranih iz izvornog skupa podataka [11]. U tu je svrhu iskorištena integrirana funkcija *clusterboot* is paketa *fpc* koja obavlja grupiranje i evaluira proizvedene klasterne. Sadrži sučelja prema velikom broju algoritama grupiranja, uključujući i hijerarhijsko i particijsko grupiranje. Ova funkcija interno računa Jaccardov koeficijent stabilnosti (omjer presjeka i unije dva različita skupa podataka) između svakog novodobivenog uzorka i uzorka iz izvornog skupa podataka koji je najbliži novodobivenom uzorku. Zatim se prosjek ovih vrijednosti uzima kao mjera stabilnosti određenog klastera. Jaccardov koeficijent stabilnosti poprima vrijednosti između 0 i 1. Klasteri čiji je koeficijent stabilnosti veći od 0.75 smatraju se valjanim i stabilnim klasterima, dok se oni čiji je koeficijent stabilnosti manji od 0.5 smatraju nestabilnim klasterima [7].

Funkcija *clusterboot* kao parametre, između ostalog, prima metodu, broj ponovljenih uzoraka i broj klastera. Prilikom korištenja funkcije, navedeni su parametri pos-

Tablica 4.1: Indikatori

I	Ime	Opis
I1	Qmax	godišnji maksimalni prosječni vršni protok, [m ³ /s]
I2	volumen	površina ispod krivulje hidrograma, [km ³]
I3	trajanje	vrijeme proteklo između početka i kraja vodnog vala, [dan]
I4	težište dan	razlika između datuma vršnog protoka i početka odgovarajuće kalendarske godine, [dan]
I5	stopa recesije	maksimalna razlika protoka između vršnog protoka i kraja vodnog vala, [m ³ /s]
I6	lokacija vršnog protoka	omjer trajanja uzlazne (rastuće) grane hidrograma do vršnog protoka u odnosu na ukupno trajanje vodnog vala, [-]
I7	stopa uspona	maksimalna razlika protoka između početka vodnog vala i vršnog protoka, [m ³ /s]

tavljeni na sljedeći način: metoda je particijsko (engl. *kmeans*) grupiranje, broj ponovljenih uzoraka iznosi 10, a broj klastera je, kao i prije, fiksiran na 3. S obzirom na to da ova funkcija računa koeficijent stabilnosti za svaki od tri klastera, za pojedino su grupiranje dobivena tri različita koeficijenta stabilnosti. Radi jednostavnije međusobne usporedbe različitih grupiranja, uzet je najmanji od dobivenih koeficijenata stabilnosti za svako grupiranje (po uzoru na [7]).

Bitno je napomenuti da samo računanje stabilnosti klastera nije dovoljno dobra mjera za određivanje njihove kvalitete, stoga se ova metoda nerijetko kombinira s vizualnom provjerom i ekspertnom analizom.

Tablica 4.2: Kombinacije indikatora

Klaster	Indikatori
kAll	I1, I2, I3, I4, I5, I6, I7
k123	I1, I2, I3
k12	I1, I2
k13	I1, I3
k14	I1, I4
k24	I2, I4
k1234	I1, I2, I3, I4
k567	I5, I6, I7
k57	I5, I7

5. Rezultati


U ovom su poglavlju predstavljeni dobiveni rezultati korištenih metoda. Na početku su opisani izdvojeni vodni valovi dobiveni metodom godišnjih maksimuma i neki osnovni podaci o njima. Nakon toga su vizualno prikazane interpolacije dobivenih vodnih valova i njihovi izračunati indikatori. Zatim je predstavljeno svako od jedanaest dobivenih grupiranja, njihovi klasteri u ovisnosti o obliku vodnih valova i koeficijenti stabilnosti. Za kraj su uspoređena četiri odabrana grupiranja: dva najbolja grupiranja prema indikatorima, bolje od dva grupiranja prema obliku te jedno lošije grupiranje prema indikatorima.

5.1. Izdvojeni vodni valovi

Primjenom metode godišnjih maksimuma na skup podataka sa VS Zagreb u vremenskom periodu 1960-2019. godine izdvojeno je 60 nezavisnih vodnih valova (jedan vodni val po kalendarskoj godini). Na slici 5.1 prikazani su svi neskaliрани izdvojeni vodni valovi. Vodni valovi su u prosjeku odgovorni za 19,2% ukupnog godišnjeg volumena, dok prosječan maksimalni vršni protok po godini iznosi $1667 \text{ m}^3/\text{s}$.

Većina maksimalnih godišnjih protoka vodnih valova dogodila se u jesen i zimu, između listopada i siječnja. Naime, u listopadu, prosincu i siječnju dogodilo ih se devet, a u studenom čak dvanaest. U proljeće su poplavni valovi rjeđi, u ožujku se dogodilo sedam maksimalnih godišnjih protoka, u travnju tri, a u svibnju četiri. Ipak, najmanje je poplavnih valova u ljetnim mjesecima s obzirom na to da su se u lipnju i srpnju dogodila dva godišnja maksimuma, a u kolovožu samo jedan. Ovi su rezultati povezani s klasifikacijom godišnjeg hoda protoka rijeke Save kod Zagreba u peripanonski snježno-kišni režim i klimatskim promjenama [12].

Vodni val kojem je trebalo najviše vremena da dostigne svoj vršni protok dogodio se 1995. godine i to je trajalo 20 dana, dok se vodni val za koji je proteklo najviše vremena od njegova vršnog protoka pa do kraja dogodio 1991. i to je trajalo 38 dana. Prosječno trajanje između početka i maksimuma vodnih valova iznosi 6.317 dana, dok




Slika 5.1: Vodni valovi za razdoblje 1960-2019.

prosječno trajanje između maksimuma i kraja vodnih valova iznosi 16.37 dana. Za potrebe interpolacije, vodnim je valovima po potrebi produljen lijevi rep tako da traje 20 dana i desni rep tako da traje 38 dana.

Nakon produljenja repova valova i skaliranja vrijednosti njihova protoka, vodni su valovi interpolirani prethodno navedenim funkcijama. Na slici 5.2 prikazani su svi izdvojeni vodni valovi interpolirani B-splajnovima (a) i Fourierovim transformacijama (b) u odnosu na vodne valove u izvornom obliku (c).

Dodatni parametri/indikatora izračunati su na skupu podataka prije produljenja repova i skaliranja. U tablici 5.1 dan je statistički sažetak izračunatih indikatora koji uključuje minimalnu vrijednost, prvi kvartil (X1), medijan, prosjek, treći kvartil (X3) i maksimalnu vrijednost, dok su na slici 5.3 prikazani usporedni boxplot grafovi standardiziranih vrijednosti indikatora. Iz boxplot grafa može se vidjeti da je maksimalna vrijednost vršnog protoka $3005 \text{ m}^3/\text{s}$ (1964. godine) zapravo stršuća vrijednost i ne pripada intervalu uobičajenih vrijednosti vršnih protoka. Indikator I3 (trajanje vodnog vala) potvrđuje da se većina poplavnih vodnih valova događa u zadnjem kvartalu go-



Slika 5.2: Interpolacija vodnih valova.

dine s obzirom na to da je medijan razlike između datuma vršnih protoka i početaka odgovarajuće kalendarske godine 272 dana. Indikator I5 (stopa recesije) je u prosjeku uvijek manji od indikatora I7 (stopa uspona) što odgovara poznatom mehanizmu procesa otjecanja i formiranja vodnog vala gdje vodni valovi brže rastu nego što padaju. To potvrđuje indikator I6 (lokacija vršnog protoka) s prosjekom od 0.28405, što znači da se vršni protok određenog vodnog vala na VS Zagreb prosječno javlja ubrzo nakon četvrtine ukupnog trajanja cijelog vodnog vala. Iz vizualizacije indikatora boxplot grafovima na slici 5.3 može se pretpostaviti da su indikatori korelirani, što podupire činjenica da su svi indikatori pokazatelji istog procesa.

5.2. Pregled dobivenih klastera

Nakon izdvajanja 60 nezavisnih vodnih valova, interpolacije i računanja dodatnih indikatora, sljedeći je korak bio grupiranje spomenutih vodnih valova u klastere. Formirano je jedanaest različitih klastera. Pritom su dva temeljena na grupiranju prema obliku, a ostalih devet na grupiranju prema kombinacijama indikatora prethodno navedenim u tablici 4.2. U nastavku su dani grafički prikazi svih klastera te njihovi koeficijenti stabilnosti. Svaki grafički prikaz sastoji se od tri klastera dobivenih na temelju izabranog grupiranja i prikazuje oblike vodnih valova koji pripadaju određenom klasteru kako bi se kasnije domenskim stručnjacima olakšala analiza i potencijalno

Tablica 5.1: Sažetak indikatora.

I	Ime, [jedinica]	min	X1	$\tilde{x}$	$\bar{x}$	X3	max
I1	Qmax, [m ³ /s]	980	1352	1643	1667	1942	3005
I2	volumen, [km ³]	0.3989	0.8535	1.2120	1.1736	1.4013	2.2851
I3	trajanje, [dan]	8.00	16.00	21.00	22.68	29.00	46.00
I4	težište, [dan]	1.00	91.5	272.0	211.1	359.0	310.2
I5	stopa recesije, [m ³ /s]	148.0	351.8	439.5	463.4	578.5	845.0
I6	lokacija Qmax, [-]	0.0714	0.1735	0.2500	0.2841	0.3588	0.64516
I7	stopa uspona, [m ³ /s]	170	529.2	742.5	776.9	1014.2	1577

pronašla određena korelacija sa samim oblikom vodnih valova, ali i kako bi se vizualno procijenila kvaliteta grupiranja.


5.2.1. Grupiranje prema obliku, *B-spline* interpolacija

Klasteri prikazani na slici 5.4 rezultat su grupiranja valova prema obliku na temelju interpolacije B-splajnovima. Može se uočiti da se u prvom klasteru pojavljuju sekundarni vrhovi lijevo od vršnog protoka, u trećem klasteru se sekundarni vrhovi pojavljuju desno od vršnog protoka, dok u drugom klasteru nema uočljivih sekundarnih vrhova.

Koeficijenti stabilnosti ovih klastera iznose redom: 0.7483, 0.6567 i 0.6451. Sve su vrijednosti iznad 0.5, što znači da su donekle stabilni, ali samo bi se prvi klaster mogao smatrati potencijalno valjanim klasterom, s obzirom na to da je njegov koeficijent stabilnosti vrlo blizu 0.75. Treći klaster ima najmanji koeficijent stabilnosti, što se podudara s njegovim grafičkim prikazom na kojem se očituje određena varijabilnost.

5.2.2. Grupiranje prema obliku, Fourier

Klasteri prikazani na slici 5.5 također su rezultat grupiranja vodnih valova prema obliku, ali na temelju interpolacije Fourierovim transformacijama. Ovdje su također u prvi klaster grupirani vodni valovi kojima su sekundarni vrhovi s lijeve strane, u treći su grupirani vodni valovi kojima su sekundarni vrhovi s desne strane, dok su u drugi klaster grupirani vodni valovi bez uočljivih sekundarnih vrhova.




Slika 5.3: Boxplot indikatora.

Koeficijenti stabilnosti ovih klastera iznose redom: 0.6517, 0.5671 i 0.5044. Svi su klasteri tehnički stabilni ali koeficijent stabilnosti nijednog klastera nije značajno blizu 0.75, pa je upitno koliko su zapravo valjani. Treći klaster čak nije daleko od toga da bude klasificiran kao nestabilan klaster.


5.2.3. Grupiranje prema indikatorima I1-I7

Klasteri prikazani na slici 5.6 dobiveni su grupiranjem vodnih valova prema svim dodatno izračunatim indikatorima: I1 (Qmax), I2 (volumen), I3 (trajanje), I4 (težište), I5 (stopa recesije), I6 (lokacija Qmax) i I7 (stopa uspona). Ovdje na grafičkom prikazu postoji više varijabilnosti unutar samih klastera nego u slučaju prethodna dva grupiranja s obzirom da se vodni valovi u ovom slučaju ne grupiraju prema obliku.

Koeficijenti stabilnosti ovih klastera iznose redom: 0.7991, 0.5122 i 0.3943. U ovom se slučaju dogodilo prethodno spomenuto stvaranje klastera u kojem se nalaze vrijednosti koje nigdje ne pripadaju. Koeficijent stabilnosti prvog klastera vrlo je visok i premašuje prag od 0.75, no zato koeficijent stabilnosti trećeg klastera nije ni blizu 0.5 i ne može se smatrati stabilnim. To znači da je treći klaster određena vrsta "koša" u koji se svrstavaju podaci koje algoritam nije uspio grupirati.



Slika 5.4: Klasteri dobiveni grupiranjem prema obliku (B-splajnovi).




Slika 5.5: Klasteri dobiveni grupiranjem prema obliku (Fourier).

5.2.4. Grupiranje prema indikatorima I1, I2, I3


Klasteri prikazani na slici 5.7 dobiveni su grupiranjem prema indikatorima I1 (Q_{max}), I2 (volumen) i I3 (trajanje) koji pripadaju osnovnim hidrološkim indikatorima poplavnih valova.

Koeficijenti stabilnosti ovih klastera iznose redom: 0.6040, 0.7013 i 0.6857. Svi premašuju prag od 0.5 i mogu se smatrati stabilnim klasterima. Iako nijedan ne doseže dovoljno veliku vrijednost da bi se smatrali valjanima, svi su klasteri podjednako stabilni i nijedan ne služi za vodne valove koji nigdje ne pripadaju. U ovom je slučaju zanimljivo to što, iako bi se na temelju grafičkog prikaza moglo zaključiti da u drugom klasteru postoji najviše varijabilnosti, taj klaster zapravo ima najveći koeficijent



Slika 5.6: Klasteri dobiveni grupiranjem prema I1-I7.

stabilnosti.




Slika 5.7: Klasteri dobiveni grupiranjem prema I1, I2, I3.

5.2.5. Grupiranje prema indikatorima I1, I2

Klasteri prikazani na slici 5.8 dobiveni su grupiranjem prema indikatorima I1 (Q_{max}) i I2 (volumen) koji predstavljaju bitne karakteristike povezane s količinom vode pojedinog vodnog vala.

Koeficijenti stabilnosti ovih klastera iznose redom: 0.3717, 0.6682 i 0.5600. I u slučaju ovog grupiranja dogodilo se da postoji jedan klaster s koeficijentom manjim od 0.5, što znači da dotični klaster nije stabilan. Na samom se grafičkom prikazu također

jasno očituju varijabilnosti unutar pojedinog klastera, izuzev drugog klastera čiji je koeficijent stabilnosti najveći.




Slika 5.8: Klasteri dobiveni grupiranjem prema I1, I2.

5.2.6. Grupiranje prema indikatorima I1, I3

Klasteri prikazani na slici 5.9 dobiveni su grupiranjem prema indikatorima I1 (Q_{max}) i I3 (trajanje).

Koeficijenti stabilnosti ovih klastera iznose redom: 0.6685, 0.6951 i 0.6572. Iako se na grafičkom prikazu očituje varijabilnost u svakom od klastera, svi se oni mogu smatrati stabilnima. Koeficijenti su također relativno podjednaki.




Slika 5.9: Klasteri dobiveni grupiranjem prema I1, I3.

5.2.7. Grupiranje prema indikatorima I1, I4

Klasteri prikazani na slici 5.10 dobiveni su grupiranjem prema indikatorima I1 (Q_{max}) i I4 (težište).

Koeficijenti stabilnosti ovih klastera iznose redom: 0.8437, 0.7772 i 0.9044. Svi se klasteri mogu smatrati stabilnima, ali i valjanima s obzirom na to da uvjerljivo prelaze prag od 0.75.



Slika 5.10: Klasteri dobiveni grupiranjem prema I1, I4.

5.2.8. Grupiranje prema indikatorima I2, I4


Klasteri prikazani na slici 5.11 dobiveni su grupiranjem prema indikatorima I2 (volumen) i I4 (težište).

Koeficijenti stabilnosti ovih klastera iznose redom: 0.8995, 0.8839 i 0.9319. Ovi su koeficijenti najbolji dosad, svi su veći od 0.88 što znači da su izrazito stabilni i valjani.


5.2.9. Grupiranje prema indikatorima I1, I2, I3, I4

Klasteri prikazani na slici 5.12 dobiveni su grupiranjem prema indikatorima I1 (Q_{max}), I2 (volumen), I3 (trajanje) i I4 (težište).

Koeficijenti stabilnosti ovih klastera iznose redom: 0.6819, 0.6807 i 0.6366. Svi su klasteri stabilni, ali upitno valjani s obzirom na to da nijedan koeficijent ne prelazi prag od 0.75. Na grafičkom prikazu može se primijetiti dosta varijabilnosti u pojedinom klasteru.



Slika 5.11: Klasteri dobiveni grupiranjem prema I2, I4.



Slika 5.12: Klasteri dobiveni grupiranjem prema I1, I2, I3, I4.


5.2.10. Grupiranje prema indikatorima I5, I6, I7

Klasteri prikazani na slici 5.13 dobiveni su grupiranjem prema indikatorima I5 (stopa recesije), I6 (lokacija Q_{max}) i I7 (stopa uspona).

Koeficijenti stabilnosti ovih klastera iznose redom: 0.8334, 0.7493 i 0.7305. Svi su klasteri stabilni i potencijalno valjani s obzirom na to da prvi klaster svakako premašuje prag od 0.75, a ostala dva nisu daleko.


5.2.11. Grupiranje prema indikatorima I5, I7

Klasteri prikazani na slici 5.14 dobiveni su grupiranjem prema indikatorima I5 (stopa recesije) i I7 (stopa uspona).



Slika 5.13: Klasteri dobiveni grupiranjem prema I5, I6, I7.

Koeficijenti stabilnosti ovih klastera iznose redom: 0.8731, 0.7967 i 0.8006. Ovi su klasteri svakako stabilni i valjani.



Slika 5.14: Klasteri dobiveni grupiranjem prema I5, I7.

5.3. Usporedba rezultata

Kao što je prethodno objašnjeno, pojedina su grupiranja uspoređena tako da je uspoređen najmanji od tri koeficijenta stabilnosti klastera. Pritom grupiranja prema obliku nisu uspoređivana s grupiranjima prema dodatnim indikatorima, već isključivo međusobno, s obzirom na to da je korišten različit pristup grupiranja. U tablici 5.2 navedena su sva grupiranja, prosjek koeficijenta stabilnosti njihovih klastera te najmanji od tri

koeficijenta stabilnosti. Iz tablice se može očitati da je uvjerljivo najbolje grupiranje ono prema indikatorima I2 i I4, a najlošije grupiranje prema indikatorima I1 i I4. Zanimljivo je i da je grupiranje općenito kvalitetnije kad ne grupiramo prema svim izračunatim indikatorima, već kad izdvojimo, odnosno uklonimo određene indikatore, što je vjerojatno utjecaj činjenice da je većina indikatora međusobno korelirana. Grupiranje prema svim indikatorima daje prosječan koeficijent stabilnosti od 0.5685, dok recimo grupiranje prema izdvojenim indikatorima I1, I2, I3 i I4 daje veći prosječan koeficijent od 0.6664. Isti je slučaj i s grupiranjem prema indikatorima I5, I6 i I7 koje daje prosječan koeficijent stabilnosti od 0.7711, dok grupiranje samo prema I5 i I6 daje prosječan koeficijent od 0.8234, što je značajno veći rezultat. Grupiranje prema dodatnim indikatorima daje općenito bolji rezultat od grupiranja prema obliku, a što se tiče samog grupiranja prema obliku, bolji se rezultat u ovom slučaju postiže *B-spline* interpolacijom.


Tablica 5.2: Stabilnost klastera

Grupiranje	$\tilde{x}$	min
<i>B-spline</i>	0.6834	0.6451
Fourier	0.5744	0.5044
I1-I7	0.5685	0.3943
I1, I2, I3	0.6637	0.6040
I1, I2	0.5333	0.3717
I1, I3	0.6736	0.6572
I1, I4	0.8418	0.7772
I2, I4	0.9051	0.8839
I1, I2, I3, I4	0.6664	0.6366
I5, I6, I7	0.7711	0.7305
I5, I7	0.8234	0.7967


U nastavku je prikazana diskusija grupiranja prema I2 i I4, grupiranja prema I5, i I7, s obzirom na to da nemaju dijeljenih indikatora, a daju dva najbolja rezultata, grupiranja prema I1-I7 kao primjer nešto lošijeg rezultata te grupiranja prema obliku temeljenog na *B-spline* interpolaciji, kao bolju varijantu grupiranja prema obliku.

Na slici 5.15 prikazani su boxplot grafovi indikatora I2 (a), odnosno I4 (b) na temelju grupiranja prema navedenim indikatorima. Prvi boxplot predstavlja vrijednosti odabranog indikatora za sve podatke, dok ostala tri predstavljaju njegove vrijednosti za podatke u pojedinom klasteru s obzirom na grupiranje prema navedenim indikatorima.

Na prvom je grafu vidljivo da uopće nema preklapanja boxplotova između klastera, što je dobar znak kvalitetnog grupiranja podataka. Na drugom grafu postoji određeno preklapanje između boxplotova prvog i drugog klastera, dok je graf trećeg klastera potpuno odvojen od ostalih, što se nadovezuje na činjenicu da treći klaster ovog grupiranja ima najveći koeficijent stabilnosti.




(a) I2-volumen




(b) I4-težište

Slika 5.15: Boxplot indikatora I2, I4.

Na slici 5.16 su na isti način prikazani boxplot grafovi indikatora I5 (a) i I7 (b) na temelju grupiranja prema navedenim indikatorima. Na prvom grafu može se vidjeti da postoji preklapanje u boxplotovima drugog i trećeg klastera, dok je prvi klaster u potpunosti izdvojen, što se podudara s činjenicom da prvi klaster ima najveći koeficijent stabilnosti. Na drugom su grafu boxplotovi klastera gotovo u potpunosti odvojeni, što je opet dobar znak kvalitete grupiranja.



(a) I5-stopa recesije




(b) I7-stopa uspona


Slika 5.16: Boxplot indikatora I5, I7.

Na slici 5.17 su također na isti način prikazani indikatori I1 (a) i I6 (b) na temelju grupiranja prema indikatorima I1-I7 koje ima lošiji rezultat i samim je time manje kvalitetno nego prethodna dva grupiranja. Na prvom je grafu boxplot prvog klastera čak izdvojen od ostatka, no boxplotovi drugog i trećeg grafa vrlo su slični. Još je lošija situacija u slučaju drugog grafa, gdje se sva tri boxplota preklapaju.

U svrhu usporedbe grupiranja prema indikatorima s grupiranjem prema obliku, za svaki od odabrana tri grupiranja prema indikatorima izračunat je omjer preklapanja klastera s klasterima dobivenim grupiranjem prema obliku (Fourier). Za dva klastera omjer je izračunat kao broj vodnih valova koji se nalaze u obje klase podijeljen sa zbrojem broja vodnih valova u svakom klasteru. U tablici 5.3 prikazana su odabrana grupiranja prema indikatorima, njihovi klasteri i klasteri koji pripadaju grupiranju prema



(a) I1-Qmax recesije



(b) I6-lokacija Qmax

Slika 5.17: Boxplot indikatora I1, I5.


obliku, a koji se u najvećem postotku slažu sa spomenutim klasterom te omjer ta dva klastera. Iako su klasteri dobiveni grupiranjem prema indikatorima I2 i I4 najstabilniji, njihovo je poklapanje s oblikom najlošije. Najbolja dva grupiranja prema indikatorima ne podudaraju se u velikoj mjeri s oblikom. Oni naime razvrstavaju vodne valove u dva klastera, iako se većina njih oblikom svrstava u samo jedan klaster. Iako, grupiranje prema I5, I7 čini se kvalitetnije u smislu preklapanja s oblikom zbog većih omjera. Grupiranje prema I1-I7 daje dobar rezultat samo za prvi klaster, dok ostala dva daju nešto lošiji rezultat.

Za kraj je vizualno prikazan svaki od 60 izdvojenih vodnih valova, sortiranih po volumenu i grupiranih u po tri klastera koristeći metode grupiranja redom: grupiranje prema obliku - *B-spline*) (Slika 5.18), grupiranje prema I1-I7 (Slika 5.19), grupiranje


Tablica 5.3: Preklapanje klastera

Indikatori	Klaster	Klaster-oblik	omjer
I2,I4	1	1	0.2846
	2	2	0.2222
	3	2	0.2069
I5,I7	1	1	0.4561
	2	2	0.1667
	3	2	0.2222
I1-I7	1	1	0.4444
	2	2	0.1860
	3	3	0.1875


prema I2, I4 (Slika 5.20) te grupiranje prema I5, I7 (Slika 5.21). Pritom je na pojedinom grafu svaki klaster prikazan drukčijom bojom.




Slika 5.18: Klasteri dobiveni grupiranjem prema obliku (*B-spline*).



Slika 5.19: Klasteri dobiveni grupiranjem prema I1-I7.



Slika 5.20: Klasteri dobiveni grupiranjem prema I2, I4.



Slika 5.21: Klasteri dobiveni grupiranjem prema I5, I7.

6. Zaključak

Na temelju hidroloških podataka o prosječnim dnevnim protocima na VS Zagreb u periodu 1960-2019. godine, provedena je eksploratorna analiza korištenjem statističkih metoda i metoda strojnog učenja. Metodom godišnjih maksimuma izdvojeno je 60 nezavisnih vodnih valova koji su zatim grupirani prema obliku (nakon interpolacije i dodatne obrade) i prema dodatnim indikatorima koji opisuju oblik i karakteristike vodnog vala primjenom nenadziranog strojnog učenja. Od jedanaest različitih grupa klastera izabrana su dva najbolja grupiranja prema indikatorima, bolje od dva grupiranja prema obliku i jedno lošije grupiranje prema indikatorima. Same grupe i klasteri vrednovani su računanjem koeficijenata stabilnosti.

Najbolje grupiranje je ono prema volumenu i težištu vodnih valova, a grupiranje rezultatom netom nakon njega grupiranje je prema stopi recesije i stopi uspona. Što se tiče grupiranja prema obliku, *B-spline* interpolacija pokazala se kao bolji izbor jer daje stabilnije klastere, iako i ono daje općenito slabije koeficijente stabilnosti od grupiranja prema indikatorima. Međutim, ovaj pristup daje dobru osnovu za definiranje bezdimenzionalnog oblika projektnog/sintetičkog hidrograma.

S obzirom na opširnost područja istraživanja, daljnji se rad može nastaviti u nekoliko smjerova. Jedan od njih bio bi npr. promjena broja klastera i korištenje metoda za pronalazak njihovog optimalnog broja te optimalnog broja utjecajnih indikatora. Također postoji još mnogo dodatnih indikatora koji bi se mogli izračunati iz danih podataka i na temelju kojih bi se moglo provesti grupiranje. Dobivene grupe prema indikatorima i obliku potrebno je evaluirati dodatnim hidrološkim analizama od strane domenskih stručnjaka, npr. analizom učestalosti i trajanja, trenda između osnovnog skupa i dobivenih grupa. U kontekstu upravljanja rizicima od poplava može se pružiti osvrt na rezultate s obzirom i na morfološke karakteristike sliva te klimatske indikatore kao što su oborine, temperatura zraka i snježni pokrivač.

Rezultati provedene analize mogu kasnije poslužiti domenskim stručnjacima u sklopu upravljanja rizikom od poplava, stoga je kvaliteta ovakvih analiza podataka iznimno važna u hidrološkoj praksi.

LITERATURA

- [1] Marijan Babić, Darko Barbalić, Damir Bekić, Tamara Brleković, Gordana Bušelić, Ivana Ivanković, Josip Rubinić, and Berislav Rupčić. *PROGRAM TEHNIČKE SMJERNICA U HIDROLOGIJI*. Hrvatska komora inženjera građevinarstva, 2021.
- [2] Alen Čenanović. *Analiza hidrograma velikih voda na VS Zagreb, Završni rad*, 2021.
- [3] Husno Hrelja. *Inženjerska hidrologija*, 2007.
- [4] 56 godina od velike poplave u zagrebu. <https://voda.hr/hr/novost/56-godina-od-velike-poplave-u-zagrebu>. pristupano 25.5.2023.
- [5] Šest godina od poplave u županjskoj posavini. <https://voda.hr/hr/novost/sest-godina-od-poplave-u-zupanjskoj-posavini>. pristupano 27.5.2023.
- [6] Julian D. Olden, Mark J. Kennard, and Bradley J. Pusey. A framework for hydrologic classification with a review of methodologies and applications in ecohydrology. *Ecohydrology*, 5(4):503–518, August 2011.
- [7] Alison A. Whipple, Joshua H. Viers, and Helen E. Dahlke. Flood regime typology for floodplain ecosystem management as applied to the unregulated cosumnes river of california, united states. *Ecohydrology*, 10(5), March 2017.
- [8] DHMZ. *DHMZ - Sektor za hidrologiju*.
- [9] T. Soni Madhulatha. An overview on clustering methods, 2012.
- [10] Manuela I. Brunner, Daniel Viviroli, Reinhard Furrer, Jan Seibert, and Anne-Catherine Favre. Identification of flood reactivity regions via the functional clustering of hydrographs. *Water Resources Research*, 54(3):1852–1867, March 2018.

- [11] Francis L. Huang. Using cluster bootstrapping to analyze nested data with a few clusters. *Educational and Psychological Measurement*, 78(2):297–318, November 2016.
- [12] Ivan Čanjevac. *Promjene i tipologija režima protoka rijeka u Hrvatskoj, Doktorska disertacija*, 2012.

Primjena metoda statistike i strojnog učenja za analizu vodnih valova

Sažetak

Poplave mogu uzrokovati značajne gospodarske štete i ugroziti ljudske živote. U ovom radu napravljena je eksploratorna analiza podataka primjenom metoda statistike i strojnog učenja kako bi kasnije pomogla domenskim stručnjacima u upravljanju rizikom od poplava. Izdvojeni su nezavisni vodni valovi metodom godišnjih maksimuma, izračunati su dodatni indikatori na temelju izvornih podataka te su vodni valovi zatim grupirani prema obliku (na temelju interpolacije) i prema dodatnim indikatorima u po tri klastera koristeći particijsko grupiranje. Na kraju su predstavljene i uspoređene dobivene grupe klastera.

Ključne riječi: Statistika, Strojno učenje, Grupiranje, Klasteri, Poplavni valovi.

Application of statistics and machine learning methods for the analysis of hydrological data

Abstract

Floods can cause significant economic damage and endanger human lives. In this study, an exploratory data analysis was conducted using statistical methods and machine learning to later assist domain experts in flood risk management. Independent water waves were extracted using the annual maxima method, additional indicators were calculated based on the original data, and the water waves were then grouped according to shape (based on interpolation) and additional indicators into three clusters using partition clustering. Finally, the obtained cluster groups were presented and compared.

Keywords: Statistics, Machine Learning, Clustering, Clusters, Flood waves.